

RELATÓRIO TÉCNICO – ANÁLISE EXPLORATÓRIA E MODELO DE REGRESSÃO (IBM STOCKS)

Este relatório apresenta a Análise Exploratória de Dados (AED) e a modelagem preditiva aplicada ao dataset histórico de ações da IBM, disponível no repositório GitHub: <https://github.com/PedroJunior56/Projeto-Aplicado-II/tree/main>

A análise inclui:

- Limpeza e preparação dos dados
 - Estatísticas descritivas
 - Correlações entre variáveis financeiras
 - Visualizações exploratórias
 - Modelagem por Regressão Linear
 - Avaliação por métricas (MAE, RMSE, MAPE, MSE, R^2)
 - Conclusões e recomendações técnicas
-

1. Contexto e Objetivos do Projeto

O projeto faz parte de um Trabalho Aplicado de Ciência de Dados com foco em compreender o comportamento do mercado financeiro por meio da série histórica das ações da IBM.

Objetivos específicos

1. Realizar a limpeza e transformação do dataset.
2. Investigar estatísticas de tendência central e dispersão.
3. Avaliar correlações entre preços e volume.
4. Criar um modelo de Regressão Linear para prever o volume de negociações.
5. Avaliar a performance do modelo e discutir limitações.
6. Registrar conclusões, aprendizados e recomendações para melhorias futuras.

2. Base de Dados Utilizada

- Fonte: Kaggle – “International Business Machines Stocks from 2000”.
- Arquivo: IBM.csv
- Registros: 6118 linhas
- Colunas: 7 colunas

Coluna	Descrição
Date	Data da negociação
Open	Preço de abertura
High	Máximo do dia
Low	Mínimo do dia
Close	Preço de fechamento
Adj Close	Preço ajustado (por dividendos, splits)
Volume	Número de ações negociadas

Dataset sem dados pessoalmente sensíveis.

3. Limpeza e Preparação dos Dados

As etapas aplicadas foram:

- Conversão da coluna Date para formato datetime
- Ordenação crescente pela data
- Remoção de valores nulos (dropna)
- Remoção de duplicatas
- Arredondamento de valores numéricos
- Conversão de tipos numéricos apropriados
- Inspeção de outliers usando estatísticas descritivas

Essa preparação garantiu consistência para as análises seguintes.

4. Análise Exploratória de Dados (AED)

4.1 Estatísticas Descritivas Foram

calculadas:

- Média
- Mediana
- Desvio padrão
- Assimetria
- Curtose

A análise indica:

- As colunas Open, High, Low, Close são extremamente semelhantes entre si (alta redundância).
- A coluna Adj Close é altamente correlacionada com os preços (mas sofre ajustes de dividendos).
- O Volume apresenta distribuição distinta, maior variabilidade e não segue o mesmo padrão das variáveis de preço.

4.2 Matriz de Correlação Insights importantes:

- Correlações entre preços (Open, High, Low, Close) ≈ 0.999
- Adj Close também é altamente correlacionado ($\sim 0.87-0.90$)
- Volume tem correlação fraca com todas as variáveis de preço

Conclusão: as variáveis de preço não explicam bem o comportamento do volume.

5. Modelagem – Regressão Linear

Foi aplicada uma Regressão Linear Simples:

- Variável explicativa (X): Adj Close
- Variável alvo (y): Volume
- Divisão: 70% treino / 30% teste

Objetivo: testar se o preço ajustado consegue prever o volume negociado.

6. Avaliação do Modelo

A partir dos cálculos, obtiveram-se as seguintes métricas:

Métrica	Valor
MAE	1,093
RMSE	1,651
MAPE	0,993%
MSE	2,726
R^2	0,165

Interpretação Técnica

- **Baixa Acurácia (R^2):** O coeficiente de determinação $R^2 = 0,165$ indica que o modelo de Regressão Linear Simples consegue explicar apenas 16,5% da variância total do volume negociado. Este resultado confirma a conclusão da AED de que a variável Adj Close tem uma correlação fraca com o volume e é um preditor inadequado para essa variável-alvo.
- **Erros Absolutos:** O MAE de 1,093 indica que o erro médio de previsão do preço, na moeda original (dólares), é de aproximadamente 1,09. O RMSE de 1,651 é notavelmente maior que o MAE. A diferença (RMSE - MAE) 0,558 sugere que o modelo Naive, embora simples, produz desvios significativos em alguns pontos, que são penalizados pelo termo quadrático do RMSE.
- **O MAPE inferior a 1% (0,993%)** demonstra que o modelo Naive já alcança uma boa precisão em termos percentuais, servindo como um ponto de partida robusto para modelos mais complexos.
- Os intervalos estreitos observados nas três métricas reforçam a alta estabilidade do modelo Naive.

7. Limitações e Considerações Técnicas

1. Volume é influenciado por muitos fatores externos (notícias, mercado, investidores institucionais).
2. Relação com preço não é linear.
3. Pode haver heterocedasticidade (variância instável).
4. Presença de outliers afeta RMSE.

8. Conclusão

A análise demonstrou que:

- Os preços das ações da IBM são altamente correlacionados entre si.
- O volume de negociações tem comportamento independente e muito mais volátil.
- O modelo de regressão linear simples não é adequado para prever volume com boa precisão.
- A performance baixa do modelo é esperada dada a natureza dos dados.
- Futuras análises devem considerar modelos multivariados e técnicas próprias de séries temporais.