

RELATÓRIO TÉCNICO – ANÁLISE EXPLORATÓRIA E MODELO DE REGRESSÃO (IBM STOCKS)

Este relatório apresenta a Análise Exploratória de Dados (AED) e a modelagem preditiva aplicada ao dataset histórico de ações da IBM, disponível no repositório GitHub:

<https://github.com/PedroJunior56/Projeto-Aplicado-II/blob/main/scripts/AED.ipynb>

A análise inclui:

- Limpeza e preparação dos dados
- Estatísticas descritivas
- Correlações entre variáveis financeiras
- Visualizações exploratórias
- Modelagem por Regressão Linear
- Avaliação por métricas (MAE, RMSE, MAPE, MSE, R^2)
- Conclusões e recomendações técnicas

1. Contexto e Objetivos do Projeto

O projeto faz parte de um Trabalho Aplicado de Ciência de Dados com foco em compreender o comportamento do mercado financeiro por meio da série histórica das ações da IBM.

Objetivos específicos

1. Realizar a limpeza e transformação do dataset.
2. Investigar estatísticas de tendência central e dispersão.
3. Avaliar correlações entre preços e volume.
4. Criar um modelo de Regressão Linear para prever o volume de negociações.
5. Avaliar a performance do modelo e discutir limitações.
6. Registrar conclusões, aprendizados e recomendações para melhorias futuras.

2. Base de Dados Utilizada

- Fonte: Kaggle – “International Business Machines Stocks from 2000”.
- Arquivo: IBM.csv
- Registros: 6118 linhas
- Colunas: 7 colunas

Coluna	Descrição
--------	-----------

Date	Data da negociação
------	--------------------

Open	Preço de abertura
------	-------------------

High	Máximo do dia
------	---------------

Low	Mínimo do dia
-----	---------------

Close	Preço de fechamento
-------	---------------------

Adj Close	Preço ajustado (por dividendos, splits)
-----------	---

Volume	Número de ações negociadas
--------	----------------------------

Dataset sem dados pessoalmente sensíveis.

3. Limpeza e Preparação dos Dados

As etapas aplicadas foram:

- Conversão da coluna Date para formato datetime
- Ordenação crescente pela data
- Remoção de valores nulos (dropna)
- Remoção de duplicatas
- Arredondamento de valores numéricos
- Conversão de tipos numéricos apropriados
- Inspeção de outliers usando estatísticas descritivas

Essa preparação garantiu consistência para as análises seguintes.

4. Análise Exploratória de Dados (AED)

4.1 Estatísticas Descritivas

Foram calculadas:

- Média
- Mediana
- Desvio padrão
- Assimetria
- Curtose

A análise indica:

- As colunas Open, High, Low, Close são extremamente semelhantes entre si (alta redundância).
- A coluna Adj Close é altamente correlacionada com os preços (mas sofre ajustes de dividendos).
- O Volume apresenta distribuição distinta, maior variabilidade e não segue o mesmo padrão das variáveis de preço.

4.2 Matriz de Correlação

Insights importantes:

- Correlações entre preços (Open, High, Low, Close) ≈ 0.999
- Adj Close também é altamente correlacionado ($\sim 0.87-0.90$)
- Volume tem correlação fraca com todas as variáveis de preço

Conclusão: as variáveis de preço não explicam bem o comportamento do volume.

5. Modelagem – Regressão Linear

Foi aplicada uma Regressão Linear Simples:

- Variável explicativa (X): Adj Close
- Variável alvo (y): Volume
- Divisão: 70% treino / 30% teste

Objetivo: testar se o preço ajustado consegue prever o volume negociado.

6. Avaliação do Modelo

A partir dos cálculos, obtiveram-se as seguintes métricas:

Métrica	Valor
MAE	1,093
RMSE	1,651
MAPE	0,993%
MSE	2,726
R ²	0,165

Interpretação Técnica

- **Baixa Acurácia (R^2):** O coeficiente de determinação $R^2 = 0,165$ indica que o modelo de Regressão Linear Simples consegue explicar apenas 16,5% da variância total do volume negociado. Este resultado confirma a conclusão da AED de que a variável Adj Close tem uma correlação fraca com o volume e é um preditor inadequado para essa variável-alvo.
- **Erros Absolutos:** O MAE de 1,093 indica que o erro médio de previsão do preço, na moeda original (dólares), é de aproximadamente 1,09. O RMSE de 1,651 é notavelmente maior que o MAE. A diferença (RMSE - MAE) 0,558 sugere que o modelo Naive, embora simples, produz desvios significativos em alguns pontos, que são penalizados pelo termo quadrático do RMSE.
- **O MAPE inferior a 1% (0,993%)** demonstra que o modelo Naive já alcança uma boa precisão em termos percentuais, servindo como um ponto de partida robusto para modelos mais complexos.
- Os intervalos estreitos observados nas três métricas reforçam a alta estabilidade do modelo Naive.

7. Limitações e Considerações Técnicas

1. Volume é influenciado por muitos fatores externos (notícias, mercado, investidores institucionais).
 2. Relação com preço não é linear.
 3. Pode haver heterocedasticidade (variância instável).
 4. Presença de outliers afeta RMSE.
-

8. Conclusão

A análise demonstrou que:

- Os preços das ações da IBM são altamente correlacionados entre si.
- O volume de negociações tem comportamento independente e muito mais volátil.
- O modelo de regressão linear simples não é adequado para prever volume com boa precisão.
- A performance baixa do modelo é esperada dada a natureza dos dados.
- Futuras análises devem considerar modelos multivariados e técnicas próprias de séries temporais.